

FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA - FIAP
INTELIGÊNCIA ARTIFICIAL

ASSISTENTE CARDIOLÓGICO VIRTUAL COM CISÃO COMPUTACIONAL

ACADÊMICOS:

ISAAC MACIEL

RM: 98222

VINIVIU PEREIRA

RM: 564940

VITOR AUGUSTO PRADO GUISSO

RM: 562317

SUMÁRIO

1. INTRODUÇÃO	4
2. OBJETIVOS	4
3. DATASET UTILIZADO	5
4. PRÉ-PROCESSAMENTO DOS DADOS	6
4.1 Redimensionamento	6
4.2 Normalização	6
4.3 Organização dos dados	6
4.4 Data Augmentation	7
5. DESENVOLVIMENTO DOS MODELOS	8
5.1 Implementação da CNN Própria	8
5.1.1 Arquitetura da CNN Própria	8
5.1.2 Treinamento da CNN Própria	9
5.1.3 Análise do Treinamento da CNN Própria	10
5.1.4 Salvamento da CNN Própria	11
5.2 Transfer Learning com ResNet50	11
5.2.1 Preparação dos Dados para a ResNet50	11
5.2.2 Configuração da Arquitetura ResNet50	12
5.2.3 Treinamento Inicial da ResNet50	13
5.2.4 Análise do Treinamento Inicial da ResNet50	13
5.2.5 Aplicação de Fine Tuning na ResNet50	14
5.2.6 Treinamento da ResNet50 com Fine Tuning	14
5.2.7 Análise da ResNet50 com Fine Tuning	12
5.2.8 Salvamento da ResNet50	16
5.3 Transfer Learning com VGG16	17
5.3.1 Configuração da Arquitetura VGG16	17
5.3.2 Treinamento da VGG16	18
5.3.3 Análise do Treinamento da VGG16	19
5.3.4 Avaliação da VGG16 no Conjunto de Teste	20

5.3.5 Salvamento da VGG16	22
6. Comparação Geral dos Modelos	22
7. Seleção do Modelo Final	23
8. Aplicação no Contexto do CardioIA Vision	23
9. Limitações Identificadas	24
10. Possíveis Melhorias Futuras	24
11. Considerações Finais sobre o Desenvolvimento dos Modelos	25
REFERÊNCIAS.....	26

1. Introdução

A Inteligência Artificial vem transformando diversas áreas da saúde, permitindo o desenvolvimento de sistemas capazes de auxiliar profissionais médicos na análise de exames, identificação de padrões e apoio à tomada de decisão clínica.

Dentro desse contexto, a Visão Computacional se destaca por possibilitar a interpretação automática de imagens médicas por meio de técnicas avançadas de Deep Learning. Entre as aplicações mais promissoras estão a análise de radiografias, tomografias, ressonâncias magnéticas e eletrocardiogramas.

Dando continuidade ao projeto CardioIA, iniciado nas fases anteriores, esta etapa teve como objetivo investigar a utilização de Redes Neurais Convolucionais (CNNs) para classificação automática de imagens de eletrocardiogramas (ECG), transformando exames visuais em informações interpretáveis por sistemas computacionais.

O projeto buscou simular um cenário realista de apoio ao diagnóstico médico, avaliando diferentes arquiteturas de Deep Learning e comparando seus desempenhos na identificação de padrões cardíacos presentes nos exames.

2. Objetivos

2.1 Objetivo Geral

Desenvolver um protótipo de Assistente Cardiológico Virtual capaz de analisar imagens de eletrocardiogramas e classificá-las automaticamente por meio de técnicas de Visão Computacional e Deep Learning.

2.2 Objetivos Específicos

- Selecionar e analisar um dataset público de imagens médicas.
- Aplicar técnicas de pré-processamento adequadas.
- Construir uma CNN própria para classificação de imagens.
- Aplicar Transfer Learning utilizando arquiteturas pré-treinadas.
- Avaliar o desempenho dos modelos por meio de métricas quantitativas.
- Comparar os resultados obtidos.
- Desenvolver um protótipo interativo para demonstração da solução.

3. Dataset Utilizado

Foi utilizado um dataset público contendo imagens de eletrocardiogramas organizadas em quatro categorias distintas:

- Abnormal Heartbeat ECG Images;
- Myocardial Infarction ECG Images;
- Normal ECG Images;
- Post MI History ECG Images.

Essas categorias representam diferentes condições cardíacas e permitem investigar a capacidade dos modelos em distinguir padrões eletrocardiográficos associados a cada situação clínica.

Para o desenvolvimento deste projeto foi utilizado o dataset público ECG Images Dataset of Cardiac Patients, disponibilizado por Adnaan (2021) na plataforma Kaggle.





FIGURA 1 – Exemplos das quatro classes do dataset.

A análise inicial demonstrou que as imagens apresentavam resolução predominante de 2213×1572 pixels e estavam armazenadas no formato RGB.



The screenshot shows a Google Colab interface. At the top, there's a table with the following data:

	classe	largura	altura	modo
0	abnormal_heartbeat_ecg_images	2213	1572	RGB
1	abnormal_heartbeat_ecg_images	2213	1572	RGB
2	abnormal_heartbeat_ecg_images	2213	1572	RGB
3	abnormal_heartbeat_ecg_images	2213	1572	RGB
4	abnormal_heartbeat_ecg_images	2213	1572	RGB

Below the table, there's a section titled "Próximas etapas:" with two buttons: "Gerar código com df" and "New interactive sheet".

FIGURA 2 – Características das imagens analisadas.

4. Pré-processamento dos Dados

Antes do treinamento das arquiteturas de Deep Learning foi realizada uma etapa de preparação dos dados com o objetivo de padronizar as imagens e adequá-las aos requisitos dos modelos avaliados.

4.1 Redimensionamento

Embora as imagens originais do dataset apresentassem resolução de 2213×1572 pixels, todas foram redimensionadas para 224×224 pixels durante o carregamento pelos geradores do TensorFlow.

Essa escolha foi realizada para garantir compatibilidade com as arquiteturas ResNet50 e VGG16, que utilizam esse tamanho de entrada como padrão.

4.2 Normalização

Os valores dos pixels foram normalizados para o intervalo entre 0 e 1 por meio da operação de reescalonamento:

```
rescale = 1./255
```

A normalização reduz diferenças de escala entre os atributos da imagem, favorecendo a estabilidade numérica e a convergência durante o treinamento das redes neurais.

4.3 Organização dos Dados

Após o pré-processamento inicial, o dataset foi organizado em três subconjuntos independentes:

- Treinamento;

- Validação;
- Teste.

A separação dos dados permite avaliar adequadamente a capacidade de generalização dos modelos, garantindo que a avaliação final seja realizada utilizando imagens não vistas durante o treinamento.

Conjunto de Treinamento		Conjunto de Validação		Conjunto de Teste	
Classe	Imagens	Classe	Imagens	Classe	Imagens
Abnormal Heartbeat	163	Abnormal Heartbeat	35	Abnormal Heartbeat	35
Myocardial Infarction	167	Myocardial Infarction	36	Myocardial Infarction	36
Normal ECG	198	Normal ECG	43	Normal ECG	43
Post Myocardial Infarction History	120	Post Myocardial Infarction History	26	Post Myocardial Infarction History	26
Total	648	Total	140	Total	140

FIGURA 3 – Organização final dos dados após o processo de preparação.

4.4 Data Augmentation

Com o objetivo de aumentar a variabilidade dos dados disponíveis e reduzir o risco de overfitting, foram aplicadas técnicas de aumento artificial de dados utilizando a classe ImageDataGenerator.

As transformações utilizadas foram:

- Rotação de até 10 graus;
- Zoom de até 10%;
- Deslocamento horizontal de até 10%;
- Deslocamento vertical de até 10%.

Essas transformações foram aplicadas apenas ao conjunto de treinamento, preservando os conjuntos de validação e teste para uma avaliação imparcial do desempenho dos modelos.

A Figura 4, mostra todo o processo realizado nessa parte de pré-processamento. Finalizando assim a parte 1 do projeto.



FIGURA 4 – Fluxograma do pré-processamento aplicado às imagens de ECG.

5. Desenvolvimento dos Modelos

5.1 IMPLEMENTAÇÃO DA CNN PRÓPRIA

Como primeira abordagem, foi desenvolvida uma Rede Neural Convolucional própria, construída do zero. Essa arquitetura teve como objetivo servir como modelo base para comparação com as técnicas de Transfer Learning aplicadas posteriormente.

A CNN foi escolhida por ser uma das principais arquiteturas utilizadas em tarefas de Visão Computacional, especialmente em problemas de classificação de imagens. Sua estrutura permite extrair automaticamente padrões visuais por meio de camadas convolucionais, tornando-a adequada para análise de imagens médicas, como eletrocardiogramas.

No contexto deste projeto, a CNN própria foi utilizada para verificar se uma arquitetura simples, treinada diretamente sobre o dataset disponível, seria capaz de aprender padrões relevantes entre as quatro classes de ECG.

5.1.1 ARQUITETURA DA CNN PRÓPRIA

A arquitetura desenvolvida foi composta por três blocos convolucionais, responsáveis pela extração progressiva de características das imagens.

A estrutura geral do modelo foi formada pelos seguintes componentes:

- Camada convolucional com 32 filtros;
- Camada MaxPooling;
- Camada convolucional com 64 filtros;

- Camada MaxPooling;
- Camada convolucional com 128 filtros;
- Camada MaxPooling;
- Camada Flatten;
- Camada densa com 128 neurônios;
- Camada Dropout com taxa de 50%;
- Camada de saída com 4 neurônios e função Softmax.

As camadas convolucionais foram responsáveis por identificar padrões visuais presentes nos eletrocardiogramas, como linhas, curvas, regiões de maior contraste e formas características dos traçados.

As camadas MaxPooling reduziram a dimensionalidade dos mapas de características, diminuindo o custo computacional e mantendo as informações mais relevantes extraídas pelas convoluções.

Após os blocos convolucionais, foi utilizada uma camada Flatten para transformar os mapas de características em um vetor unidimensional. Esse vetor foi então processado por uma camada densa com 128 neurônios e função de ativação ReLU.

Para reduzir o risco de overfitting, foi utilizada uma camada Dropout com taxa de 50%, descartando aleatoriamente parte dos neurônios durante o treinamento.

A camada final utilizou a função Softmax, adequada para problemas de classificação multiclasse, retornando a probabilidade de cada imagem pertencer a uma das quatro classes do dataset.

O modelo foi compilado com:

- Otimizador Adam;
- Função de perda Categorical Crossentropy;
- Métrica Accuracy.

5.1.2 TREINAMENTO DA CNN PRÓPRIA

O treinamento foi realizado por 15 épocas. Durante esse processo, foram monitoradas a acurácia e a função de perda nos conjuntos de treinamento e validação.

A utilização do conjunto de validação permitiu acompanhar se o modelo estava apenas memorizando os dados de treinamento ou se estava conseguindo generalizar para imagens não vistas.

5.1.3 ANÁLISE DO TREINAMENTO DA CNN PRÓPRIA

Após o treinamento, foram gerados gráficos de acurácia e perda ao longo das épocas.




FIGURA 5 – Gráfico acurácia e perda do modelo CNN.

A análise dos gráficos demonstrou que a acurácia da CNN permaneceu próxima de 30% tanto no treinamento quanto na validação. Esse resultado indica que o modelo apresentou dificuldade para aprender padrões suficientemente discriminativos entre as quatro classes de eletrocardiogramas.

A função de perda apresentou redução inicial nas primeiras épocas, porém rapidamente se estabilizou. Esse comportamento sugere que a rede atingiu um limite de aprendizado, sem conseguir melhorar significativamente seu desempenho ao longo do treinamento.

Não foram observados sinais claros de overfitting, pois as curvas de treinamento e validação permaneceram relativamente próximas. No entanto, o desempenho geral foi baixo, indicando um possível caso de underfitting.

O underfitting ocorre quando o modelo não possui capacidade suficiente, ou não consegue aprender representações adequadas dos dados, resultando em baixo desempenho tanto no treinamento quanto na validação.

Esse resultado mostrou que a CNN própria, apesar de funcional, não foi capaz de capturar com eficiência a complexidade visual das imagens de ECG disponíveis no dataset.

Dessa forma, a CNN própria foi importante como linha de base, mas seus resultados indicaram a necessidade de testar arquiteturas mais robustas, especialmente modelos pré-treinados com Transfer Learning.

5.1.4 SALVAMENTO DA CNN PRÓPRIA

Após o treinamento, o modelo foi salvo no formato .keras.

O salvamento do modelo permite sua reutilização futura sem a necessidade de repetir todo o processo de treinamento. Essa etapa é importante para avaliações posteriores, testes com novas imagens e possível integração ao protótipo CardioIA Vision.

5.2 TRANSFER LEARNING COM RESNET50

Como segunda abordagem, foi utilizado o modelo ResNet50 por meio da técnica de Transfer Learning.

A ResNet50 é uma arquitetura profunda de Rede Neural Convolutacional desenvolvida pela Microsoft Research. Seu principal diferencial está no uso de conexões residuais, conhecidas como Residual Connections.

No projeto CardioIA Vision, a ResNet50 foi utilizada com pesos pré-treinados na base ImageNet. A ideia foi aproveitar o conhecimento visual aprendido anteriormente pelo modelo e adaptá-lo à classificação de imagens de eletrocardiogramas.

Essa abordagem é especialmente útil em projetos com quantidade limitada de imagens, pois permite reutilizar padrões visuais já aprendidos por uma rede treinada em grande escala.

5.2.1 PREPARAÇÃO DOS DADOS PARA A RESNET50

O conjunto de teste foi configurado sem embaralhamento, utilizando shuffle=False. Essa configuração é importante para manter a ordem das imagens durante a geração de previsões, relatórios de classificação e matrizes de confusão.

Os dados foram carregados corretamente nos três subconjuntos:

- Treinamento: 648 imagens;
- Validação: 140 imagens;
- Teste: 140 imagens.

Também foram identificadas corretamente as quatro classes do projeto:

- Abnormal heartbeat ecg images;
- Myocardial infarction ecg images;
- Normal ecg images;
- Post mi history ecg images.

5.2.2 CONFIGURAÇÃO DA ARQUITETURA RESNET50

A ResNet50 foi carregada com pesos pré-treinados da base ImageNet, utilizando a configuração `include_top=False`. Essa configuração remove a camada final original da rede, permitindo adicionar uma nova estrutura de classificação adaptada ao problema do projeto.

As imagens de entrada foram configuradas com dimensão $224 \times 224 \times 3$, compatíveis com a arquitetura original da ResNet50.

Inicialmente, as camadas da ResNet50 foram congeladas, ou seja, seus pesos não foram alterados durante o primeiro treinamento. Dessa forma, a rede atuou apenas como extratora de características.

Após a base ResNet50, foram adicionadas as seguintes camadas:

- GlobalAveragePooling2D;
- Camada densa com 128 neurônios e ativação ReLU;
- Dropout com taxa de 50%;
- Camada final Dense com 4 neurônios e ativação Softmax.

A camada GlobalAveragePooling2D foi utilizada para transformar os mapas de características gerados pela ResNet50 em um vetor compacto. Essa escolha reduz a quantidade de parâmetros e torna o modelo mais eficiente.

A arquitetura final apresentou:

- Parâmetros totais: 23.850.500;
- Parâmetros treináveis: 262.788;
- Parâmetros não treináveis: 23.587.712.

Como a maior parte dos parâmetros permaneceu congelada, apenas a cabeça classificadora adicionada ao modelo foi treinada inicialmente.

Model: "sequential"

Layer (type)	Output Shape	Param #
resnet50 (Functional)	(None, 7, 7, 2048)	23,587,712
global_average_pooling2d (GlobalAveragePooling2D)	(None, 2048)	0
dense (Dense)	(None, 128)	262,272
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 4)	516

Total params: 23,850,500 (90.98 MB)
Trainable params: 262,788 (1.00 MB)
Non-trainable params: 23,587,712 (89.98 MB)

FIGURA 6 – Resumo da arquitetura da ResNet50.

5.2.3 TREINAMENTO INICIAL DA RESNET50

O primeiro treinamento da ResNet50 foi realizado com as camadas convolucionais congeladas. Nessa etapa, apenas as camadas finais adicionadas ao modelo foram treinadas.

O treinamento foi executado por 10 épocas, utilizando o conjunto de treinamento para ajuste dos pesos e o conjunto de validação para acompanhamento do desempenho.

O objetivo dessa etapa foi avaliar a capacidade da ResNet50 de atuar como extratora de características visuais para as imagens de ECG.

Ao final do treinamento, a acurácia de treinamento ficou em aproximadamente 32,25%, enquanto a acurácia de validação terminou em aproximadamente 34,29%.

A função de perda apresentou redução moderada, mas permaneceu em valores próximos de 1,36 no conjunto de validação.

Esses resultados indicaram que a ResNet50, quando utilizada apenas como extratora de características congelada, apresentou desempenho superior à CNN própria, mas ainda limitado para o problema de classificação das quatro classes de ECG.

5.2.4 ANÁLISE DO TREINAMENTO INICIAL DA RESNET50

O treinamento inicial demonstrou que a ResNet50 conseguiu aprender alguns padrões relevantes, mas ainda não foi suficiente para alcançar desempenho satisfatório.

A acurácia de validação permaneceu baixa e a função de perda não apresentou redução expressiva. Isso sugere que as características extraídas pela ResNet50 pré-treinada na ImageNet não se adaptaram completamente ao domínio das imagens de eletrocardiograma.

Esse comportamento pode ser explicado pela diferença entre as imagens utilizadas no treinamento original da ImageNet e as imagens médicas analisadas neste projeto. Enquanto a ImageNet contém objetos naturais, animais, pessoas e cenas variadas, os eletrocardiogramas apresentam padrões visuais muito específicos, formados principalmente por traçados, linhas e variações sutis.

Por esse motivo, foi aplicada uma segunda etapa com Fine Tuning, permitindo ajustar parte das camadas finais da ResNet50 ao conjunto de dados do projeto.

5.2.5 APLICAÇÃO DE FINE TUNING NA RESNET50

Após o treinamento inicial, foi aplicada a técnica de Fine Tuning na ResNet50.

Nessa etapa, parte das camadas finais da arquitetura foi descongelada, permitindo que seus pesos fossem ajustados durante um novo treinamento.

As camadas iniciais foram mantidas congeladas, pois normalmente aprendem características visuais mais genéricas, como bordas, linhas e texturas. Já as camadas finais tendem a representar padrões mais específicos, sendo mais adequadas para adaptação ao novo domínio.

Para evitar alterações bruscas nos pesos pré-treinados, foi utilizado o otimizador Adam com taxa de aprendizado reduzida, configurada como `learning_rate=1e-5`.

Após o descongelamento parcial, o modelo passou a apresentar:

- Parâmetros totais: 23.850.500;
- Parâmetros treináveis: 14.712.964;
- Parâmetros não treináveis: 9.137.536.

Esse resultado confirmou que parte significativa das camadas finais da ResNet50 foi liberada para treinamento.

Model: "sequential"

Layer (type)	Output Shape	Param #
resnet50 (Functional)	(None, 7, 7, 2048)	23,587,712
global_average_pooling2d (GlobalAveragePooling2D)	(None, 2048)	0
dense (Dense)	(None, 128)	262,272
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 4)	516

Total params: 23,850,500 (90.98 MB)
Trainable params: 14,712,964 (56.13 MB)
Non-trainable params: 9,137,536 (34.86 MB)

FIGURA 7 – Resumo da arquitetura da ResNet50 após o Fine Tuning.

5.2.6 TREINAMENTO DA RESNET50 COM FINE TUNING

Com as camadas finais da ResNet50 descongeladas, foi realizado um novo treinamento por 10 épocas.

Essa etapa teve como objetivo refinar os pesos das camadas mais profundas da rede, permitindo maior adaptação aos padrões visuais presentes nas imagens de eletrocardiograma.

Durante o treinamento com Fine Tuning, a acurácia de treinamento aumentou significativamente, chegando a aproximadamente 54,94% na última época.

Entretanto, a acurácia de validação permaneceu baixa, encerrando em aproximadamente 26,43%.

A função de perda de validação também permaneceu relativamente elevada, encerrando em aproximadamente 1,30.

Esse comportamento indicou que o modelo passou a aprender melhor os dados de treinamento, mas não conseguiu generalizar adequadamente para imagens não vistas.

5.2.7 ANÁLISE DA RESNET50 COM FINE TUNING

A diferença entre a acurácia de treinamento e a acurácia de validação sugere a ocorrência de overfitting.

O modelo conseguiu se ajustar aos exemplos do conjunto de treinamento, mas teve dificuldade para aplicar esse aprendizado em novos dados. Esse comportamento mostra que o Fine Tuning aumentou a capacidade de aprendizado da ResNet50, porém também aumentou sua tendência de se adaptar excessivamente aos dados de treino.

Durante a avaliação no conjunto de teste, o modelo apresentou acurácia global de aproximadamente 25%.

A matriz de confusão indicou que o modelo passou a concentrar suas previsões principalmente na classe abnormal heartbeat ecg images.

Dos 35 exemplos dessa classe, 34 foram classificados corretamente. Isso resultou em recall de 97% para essa categoria.

No entanto, as demais classes apresentaram desempenho muito baixo. As classes myocardial infarction ecg images, normal ecg images e post mi history ecg images foram frequentemente classificadas como abnormal heartbeat ecg images.

Esse comportamento demonstra forte viés do modelo para uma única classe, prejudicando sua capacidade de classificação multiclasse.




FIGURA 8 – Matriz da confusão ResNet50 após o Fine Tuning.

Os principais fatores que podem ter contribuído para esse resultado são:

- Quantidade limitada de imagens disponíveis;
- Similaridade visual entre algumas categorias de ECG;
- Dificuldade de adaptação da ResNet50 ao domínio médico;
- Possível desbalanceamento entre classes;
- Excesso de adaptação das camadas liberadas durante o Fine Tuning.

Apesar das limitações, a etapa de Fine Tuning foi importante para compreender o comportamento da ResNet50 no contexto do projeto e serviu como base comparativa para a próxima arquitetura avaliada.

5.2.8 SALVAMENTO DA RESNET50 COM FINE TUNING

Após a etapa de Fine Tuning, o modelo ResNet50 ajustado foi salvo no formato .keras.

Esse salvamento permite reutilizar o modelo posteriormente em avaliações, testes com novas imagens ou integração com o protótipo CardioIA Vision.

5.3 TRANSFER LEARNING COM VGG16

Como terceira abordagem, foi utilizado o modelo VGG16 com Transfer Learning.

A VGG16 é uma Rede Neural Convolutacional profunda desenvolvida pelo Visual Geometry Group, da Universidade de Oxford. Sua arquitetura é conhecida pela simplicidade estrutural e pelo uso sequencial de camadas convolucionais pequenas, geralmente com filtros 3×3 .

O modelo foi originalmente treinado na base ImageNet, aprendendo padrões visuais genéricos que podem ser reutilizados em outras tarefas de classificação de imagens.

No projeto CardioIA Vision, a VGG16 foi empregada para avaliar sua capacidade de extrair características relevantes de imagens de eletrocardiogramas e comparar seu desempenho com a CNN própria e a ResNet50.

5.3.1 CONFIGURAÇÃO DA ARQUITETURA VGG16

A VGG16 foi carregada com pesos pré-treinados da ImageNet e configurada com `include_top=False`, removendo a camada classificadora original.

As imagens de entrada foram configuradas com dimensão $224 \times 224 \times 3$.

Inicialmente, todas as camadas convolucionais da VGG16 foram congeladas, permitindo que o modelo atuasse como extrator de características.

Após a base VGG16, foram adicionadas as seguintes camadas:

- GlobalAveragePooling2D;
- Camada densa com 128 neurônios e ativação ReLU;
- Dropout com taxa de 50%;
- Camada final Dense com 4 neurônios e ativação Softmax.

A saída da VGG16 possui dimensão $7 \times 7 \times 512$, representando os mapas de características extraídos das imagens. A camada GlobalAveragePooling2D converte esses mapas em um vetor de 512 atributos.

O resumo da arquitetura apresentou:

- Parâmetros totais: 14.780.868;
- Parâmetros treináveis: 66.180;
- Parâmetros não treináveis: 14.714.688.

Assim, apenas a cabeça classificadora adicionada ao modelo foi treinada, enquanto a base convolutacional permaneceu congelada.

Layer (type)	Output Shape	Param #
vgg16 (Functional)	(None, 7, 7, 512)	14,714,688
global_average_pooling2d (GlobalAveragePooling2D)	(None, 512)	0
dense (Dense)	(None, 128)	65,664
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 4)	516

Total params: 14,780,868 (56.38 MB)
 Trainable params: 66,180 (258.52 KB)
 Non-trainable params: 14,714,688 (56.13 MB)

FIGURA 9 – Resumo da arquitetura da VGG16.

5.3.2 TREINAMENTO DA VGG16

O modelo VGG16 foi treinado por 10 épocas, utilizando os mesmos conjuntos de treinamento e validação empregados nos demais modelos.

Durante o treinamento, a acurácia de treinamento aumentou progressivamente, encerrando em aproximadamente 49,85%.

A acurácia de validação atingiu aproximadamente 50,00% ao final da décima época.

A função de perda apresentou redução gradual tanto no treinamento quanto na validação. A perda de validação reduziu de aproximadamente 1,34 para 1,21 ao final do treinamento.

Esse comportamento demonstrou maior estabilidade em comparação com a ResNet50 com Fine Tuning.




FIGURA 10 – gráfico de acurácia da VGG16




FIGURA 11 – Gráfico de loss da VGG16

5.3.3 ANÁLISE DO TREINAMENTO DA VGG16

A análise das curvas de treinamento da VGG16 demonstrou comportamento mais estável em relação aos modelos anteriores.

A acurácia de treinamento apresentou crescimento gradual ao longo das épocas, enquanto a acurácia de validação, apesar de oscilar, manteve tendência geral positiva.

Diferentemente da ResNet50 com Fine Tuning, não houve divergência significativa entre as curvas de treinamento e validação. Isso indica ausência de sinais evidentes de overfitting.

A função de perda também apresentou comportamento positivo, com redução consistente tanto no treinamento quanto na validação.

Esse resultado sugere que a VGG16 conseguiu aproveitar melhor os padrões visuais aprendidos previamente na ImageNet, mesmo em um problema específico de imagens médicas.

A arquitetura apresentou melhor equilíbrio entre aprendizado e generalização, tornando-se a melhor alternativa entre os modelos avaliados.

5.3.4 AVALIAÇÃO DA VGG16 NO CONJUNTO DE TESTE

Após o treinamento, o modelo VGG16 foi avaliado no conjunto de teste.

O relatório de classificação apresentou acurácia global de aproximadamente 49%, o melhor resultado entre os modelos analisados.

As classes com melhor desempenho foram:

Abnormal heartbeat ecg images:

- Precisão: 62%;
- Recall: 91%;
- F1-score: 74%.

Myocardial infarction ecg images:

- Precisão: 40%;
- Recall: 92%;
- F1-score: 56%.

Esses resultados mostram que a VGG16 conseguiu identificar adequadamente grande parte dos exames pertencentes às classes de anormalidade cardíaca e infarto do miocárdio.

A matriz de confusão confirmou esse comportamento. Dos 35 exemplos da classe abnormal heartbeat ecg images, 32 foram classificados corretamente. Já na classe myocardial infarction ecg images, 33 dos 36 exames foram corretamente identificados.




FIGURA 12 – Matriz de confusão da VGG16

Por outro lado, o desempenho foi mais limitado nas classes normal ecg images e post mi history ecg images.

Na classe normal ecg images, apenas 3 dos 43 exames foram classificados corretamente. A maior parte foi confundida principalmente com a classe myocardial infarction ecg images.

A classe post mi history ecg images não apresentou classificações corretas, sendo frequentemente confundida com as classes de infarto e anormalidade cardíaca.

Esse comportamento sugere que o modelo conseguiu aprender padrões mais evidentes associados a alterações cardíacas e infarto, mas apresentou dificuldade para diferenciar classes visualmente semelhantes, especialmente exames normais e histórico pós-infarto.

5.3.5 SALVAMENTO DA VGG16

Após o treinamento, o modelo VGG16 foi salvo no formato .keras.

O salvamento permite que o modelo seja reutilizado futuramente sem necessidade de novo treinamento, podendo ser aplicado em testes adicionais ou integrado ao protótipo CardioIA Vision.

6. Comparação Geral dos Modelos

Após a implementação e avaliação dos três modelos, foi realizada uma comparação geral de desempenho.

Os resultados obtidos foram:

Modelo	Acurácia no teste	Principais características observadas
CNN própria	31%	Apresentou desempenho limitado, com baixa capacidade de generalização e indícios de underfitting.
ResNet50 com Fine Tuning	25%	Demonstrou evolução no treinamento, mas apresentou overfitting e forte viés para uma única classe.
VGG16	49%	Apresentou o melhor desempenho geral, com maior estabilidade e melhor capacidade de generalização.

Tabela 1 – Comparação entre os 3 modelos desenvolvidos

A CNN própria foi importante como modelo de referência, mas apresentou baixa capacidade de aprender padrões discriminativos entre as quatro classes.

A ResNet50, mesmo utilizando Transfer Learning e Fine Tuning, não conseguiu se adaptar de forma satisfatória ao conjunto de imagens de ECG. O modelo apresentou melhora no treinamento, mas baixo desempenho no teste, indicando dificuldade de generalização.

A VGG16 foi o modelo com melhor resultado geral, alcançando aproximadamente 49% de acurácia no conjunto de teste. Além disso, apresentou bom desempenho na identificação das classes relacionadas a anormalidades cardíacas e infarto do miocárdio.

7. Seleção do Modelo Final

Com base nos resultados obtidos, o modelo VGG16 foi selecionado como a melhor arquitetura desta etapa do projeto.

A escolha considerou não apenas a acurácia global, mas também o comportamento das curvas de treinamento, a matriz de confusão, o relatório de classificação e a capacidade de generalização observada.

Embora nenhum dos modelos tenha alcançado desempenho suficiente para aplicação clínica real, a VGG16 apresentou os resultados mais consistentes entre as arquiteturas testadas.

O modelo demonstrou maior capacidade para reconhecer padrões associados a anormalidades cardíacas e infarto do miocárdio, além de apresentar menor evidência de overfitting em comparação com a ResNet50 com Fine Tuning.

Por esse motivo, a VGG16 foi adotada como modelo final do protótipo CardioIA Vision nesta fase do projeto.

8. Aplicação No Contexto Do Cardioia Vision

O CardioIA Vision foi desenvolvido como um módulo de Visão Computacional voltado à classificação automática de imagens de eletrocardiogramas.

No contexto do ecossistema CardioIA, o modelo selecionado poderá atuar como uma camada inicial de triagem inteligente, auxiliando na identificação de padrões visuais associados a diferentes condições cardíacas.

É importante destacar que o sistema não tem como objetivo substituir o diagnóstico médico. A proposta é atuar como ferramenta complementar de apoio à decisão, fornecendo uma análise inicial automatizada que pode auxiliar profissionais da saúde.

Em futuras evoluções, o modelo poderá ser integrado a outros módulos do projeto CardioIA, como análise de sinais, dados clínicos, sensores IoT e sistemas de monitoramento inteligente.

Dessa forma, esta etapa demonstra como técnicas de Visão Computacional e Deep Learning podem ser aplicadas à interpretação automatizada de exames médicos, contribuindo para o desenvolvimento de soluções tecnológicas voltadas à saúde.

9. Limitações Identificadas

Apesar dos resultados obtidos, algumas limitações importantes foram observadas durante o desenvolvimento dos modelos.

A primeira limitação está relacionada à quantidade de imagens disponíveis. O dataset utilizado possui tamanho relativamente reduzido para o treinamento de modelos profundos de Deep Learning, especialmente em um problema multiclasse.

Outra limitação está relacionada à similaridade visual entre algumas categorias de eletrocardiogramas. Exames normais, exames com histórico pós-infarto e exames com alterações cardíacas podem apresentar padrões visuais semelhantes, dificultando a separação correta entre as classes.

Também foi observado que alguns modelos apresentaram tendência a concentrar suas previsões em determinadas categorias, como ocorreu com a ResNet50 com Fine Tuning.

Além disso, o uso de imagens de ECG, em vez de sinais brutos de eletrocardiograma, pode limitar a capacidade do modelo de capturar características temporais e numéricas importantes do exame.

Essas limitações demonstram que, embora o protótipo tenha alcançado os objetivos acadêmicos da fase, ainda seriam necessárias melhorias significativas para aplicações reais.

10. Possíveis Melhorias Futuras

Como trabalhos futuros, recomenda-se ampliar o conjunto de dados utilizado no treinamento, incluindo maior quantidade de imagens por classe e maior diversidade de exames.

Também poderiam ser aplicadas técnicas mais avançadas de Data Augmentation, buscando aumentar a capacidade de generalização dos modelos.

Outra estratégia importante seria realizar o balanceamento das classes, reduzindo a tendência dos modelos a favorecer categorias mais representativas ou visualmente mais evidentes.

Também podem ser avaliadas arquiteturas mais modernas de Deep Learning, como:

- EfficientNet;
- DenseNet;
- MobileNet;
- Vision Transformers.

Além disso, poderia ser realizado Fine Tuning mais controlado na VGG16, ajustando gradualmente as camadas finais da rede com taxas de aprendizado menores.

Outra possibilidade seria combinar a análise de imagens com dados clínicos ou sinais brutos de ECG, criando uma abordagem híbrida mais robusta.

Essas melhorias poderiam aumentar a capacidade de discriminação dos modelos e melhorar o desempenho em classes mais difíceis, como exames normais e histórico pós-infarto.

11. Conclusão

O desenvolvimento dos modelos permitiu comparar diferentes estratégias de Deep Learning aplicadas à classificação de imagens de eletrocardiogramas.

A CNN própria demonstrou as limitações de uma arquitetura construída do zero diante de um dataset relativamente pequeno e visualmente complexo.

A ResNet50 mostrou que o Transfer Learning pode melhorar a capacidade inicial de aprendizado, mas também evidenciou que o Fine Tuning precisa ser cuidadosamente controlado para evitar overfitting.

A VGG16 apresentou o melhor desempenho geral, alcançando a maior acurácia no conjunto de teste e demonstrando maior estabilidade durante o treinamento.

Dessa forma, a etapa de desenvolvimento dos modelos cumpriu seu objetivo principal: construir, treinar, avaliar e comparar diferentes arquiteturas de Deep Learning para selecionar a melhor abordagem para o protótipo CardioIA Vision.

O modelo VGG16 foi selecionado como a solução final desta fase, representando a alternativa mais adequada dentro das condições do dataset e dos experimentos realizados.

REFERÊNCIAS

- GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. Deep Learning. Cambridge: MIT Press, 2016.
- HE, Kaiming; ZHANG, Xiangyu; REN, Shaoqing; SUN, Jian. Deep Residual Learning for Image Recognition. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.
- SIMONYAN, Karen; ZISSERMAN, Andrew. Very Deep Convolutional Networks for Large-Scale Image Recognition. arXiv preprint arXiv:1409.1556, 2015.
- SHORTEN, Connor; KHOSHGOFTAAR, Taghi M. A survey on Image Data Augmentation for Deep Learning. Journal of Big Data, v. 6, n. 60, 2019.
- TENSORFLOW. TensorFlow Documentation. Disponível em: <https://www.tensorflow.org/>. Acesso em: 16 jun. 2026.
- KAGGLE. ECG Images Dataset. Kaggle, [s.d.]. Disponível em: <https://www.kaggle.com/datasets/erhmrai/ecg-image-data>. Acesso em: 16 jun. 2026.
- MACIEL, Isaac; PEREIRA, Vinivius; GUISSO, Vitor Augusto Prado. Pré-processamento: CardioIA Vision – Fase 4. Maringá: FIAP – Faculdade de Informática e Administração Paulista, 2026.